
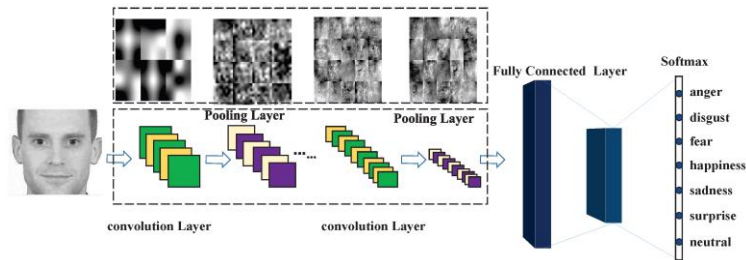


Основы искусственного интеллекта



Лекция

Обучение с учителем: Классическая регрессия

к.ф.-м.н., доцент кафедры ИСиЦТ
Корнаева Е.П.


Обучение с учителем: Классическая регрессия

Постановка задачи классической регрессии

Признаки / Features (X): свойства объекта исследования, выделяемые при обучении

Виды зависимости:

- Функциональная;
- Статистическая (в частности - корреляционная).



Известен закон(ы):

$$F_i(X_j, Y_k) = 0.$$



Известны статистические характеристики:

- законы распределения, параметры законов распределения

Обучение с учителем: Классическая регрессия

Постановка задачи классической регрессии

Регрессионный (от лат. regressio – обратное движение, отход) **анализ:**

набор статистических действий для оценки связи зависимой переменной Y и одной или нескольких независимых переменных X .

Основная идея регрессии: поиск наилучшей функциональной зависимости среднего значения зависимой переменной Y от независимых переменных X по критерию минимума некоторой функции качества.




Рис. 4.1. Линейная регрессия

По выборке можно найти только оценку уравнения регрессии:

$$y(X) = \bar{y}(X) + \varepsilon$$

Пример линейной регрессии для данных на рис. 4.1:

$$\bar{y}(x) = \theta_0 + \theta_1 x$$

Скалярная форма записи:

$h(x) = \bar{y}(x)$ – оценка регрессии (функция гипотезы h)

Обучение с учителем: Классическая регрессия

Постановка задачи классической регрессии

Данные выборки представлены множеством пар: $\{(X_i, y_i)\}, i = \overline{1, n}$




Рис. 4.1. Линейная регрессия

Пример линейной однофакторной регрессии для данных на рис. 4.1:

$$h(x) = \theta_0 + \theta_1 x_1 = \theta_j x_j, \quad j = \overline{0, 1}$$

Матричная форма записи:

$$H(\theta, X) = X\theta$$

$\theta = \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix}$ - весовые коэф-ты; $Y = \begin{pmatrix} y_0 \\ \dots \\ y_n \end{pmatrix}$ - матрица значений отклика;

$X = \begin{pmatrix} 1 & x_{11} \\ \dots & \dots \\ 1 & x_{n1} \end{pmatrix}$ - матрица значений признаков.


Функция качества (средняя ^{кв.} ошибка): **МНК**

$$J(\underline{\theta}_0, \underline{\theta}_1) = \frac{1}{n} \sum_{i=1}^n (h(\theta, X_i) - y_i)^2 \Rightarrow \min$$

Обучение с учителем: Классическая регрессия


Какие должны быть параметры модели (т.е. весовые коэффициенты)? Пример.

Наглядный выбор параметров модели (рис. 4.2а)



Формализованный выбор параметров модели (рис. 4.2б):

$$J(\theta_1) = \frac{1}{n} \sum_{i=1}^n (\theta_1 x_i - y_{\text{э}i})^2 \rightarrow \min$$



x	y
0	0
1	0,5
2	1
3	1,5
4	2



Рис. 4.2

Обучение с учителем: Классическая регрессия


- МНК. Линейная однофакторная регрессия

x	y
0	1
1	1,5
2	2
3	2,5
4	3

$$y(x) = \theta_0 + \theta_1 x$$



$$J(\theta_0, \theta_1) = \frac{1}{n} \sum_{i=1}^n (\theta_0 + \theta_1 x_i - y_{\text{э}i})^2 \rightarrow \min$$



Обучение с учителем: Классическая регрессия

Линейная регрессия в общем виде:

$$y(x_1, \dots, x_m) = \theta_0 + \theta_j x_j = \theta_j x_j^*, \quad j = \overline{0, m}$$

m=2:

$$y(x_1, x_2) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$$

Функция качества (функция ошибки):

$$J(\theta_0, \theta_1, \theta_2) = \frac{1}{n} \sum_{i=1}^n (\theta_0 + \theta_1 x_{i1} + \theta_2 x_{i2} - y_i)^2 \rightarrow \min$$

$$\frac{\partial J}{\partial \theta_j} = 0, j = 0..2$$

	X_0	X_1	X_2	Y
1	1	x_{11}	x_{12}	y_1
2	1	x_{21}	x_{22}	y_2
	...			
n	1	x_{n1}	x_{n2}	y_n

$\underbrace{\hspace{10em}}_{\mathbf{X}}$

* Используется правило Эйнштейна

Обучение с учителем: Классическая регрессия

Постановка задачи классической регрессии

Обобщение для линейной регрессии на m факторов:

Например, $m=2$:

$$y(x_1, x_2) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$$

$$g(x, y) =$$

$$g(x, y) = (5x + y)^2 = f^2(x, y)$$

$$g'_x = 2f \cdot 5 = 10(5x + y)$$

Функция качества (функция ошибки):

$$J(\theta_0, \theta_1, \theta_2) = \frac{1}{n} \sum_{i=1}^n (\theta_0^{x_{i0}} + \theta_1 x_{i1} + \theta_2 x_{i2} - y_i)^2 \rightarrow \min$$

$$\frac{1}{n} \sum_{i=1}^n x_{i0} (\theta_0 x_{i0} + \theta_1 x_{i1} + \theta_2 x_{i2} - y_{yi}) = 0$$

$$\frac{1}{n} \sum_{i=1}^n x_{i1} (\theta_0 x_{i0} + \theta_1 x_{i1} + \theta_2 x_{i2} - y_{yi}) = 0$$

$$\frac{1}{n} \sum_{i=1}^n x_{i2} (\theta_0 x_{i0} + \theta_1 x_{i1} + \theta_2 x_{i2} - y_{yi}) = 0$$

$$\frac{\partial J}{\partial \theta_j} = 0 : \sum_i x_{ij} (\theta_0 x_{i0} + \theta_1 x_{i1} + \theta_2 x_{i2} - y_{yi}) = 0$$

Обучение с учителем: Классическая регрессия

Постановка задачи классической регрессии

Обобщение для линейной регрессии на m факторов:

Например, $m=2$:

$$y(x_1, x_2) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$$

$$\frac{\partial J}{\partial \theta_j} = 0, j = 0..2$$

$$\begin{aligned} A &= X^T X & \theta &= \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix} & F &= X^T Y \\ \begin{bmatrix} \sum_i (x_{i0}^2) & \sum_i x_{i0} x_{i1} & \sum_i x_{i0} x_{i2} \\ \sum_i x_{i1} x_{i0} & \sum_i (x_{i1}^2) & \sum_i x_{i1} x_{i2} \\ \sum_i (x_{i2} x_{i0}) & \sum_i (x_{i2} x_{i1}) & \sum_i x_{i2}^2 \end{bmatrix} & \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix} & = & \begin{bmatrix} \sum_i x_{i0} y_i \\ \sum_i x_{i1} y_i \\ \sum_i x_{i2} y_i \end{bmatrix} \end{aligned}$$

$$A \theta = F \Rightarrow \theta = A^{-1} F$$

Обучение с учителем: Классическая регрессия

Постановка задачи классической регрессии

Обобщение для линейной регрессии на m факторов. Аналитическое решение

$$\frac{\partial J}{\partial \theta_j} = 0, j = 0..2$$

$$\mathbf{X}^T \mathbf{X} \boldsymbol{\theta} = \mathbf{X}^T \mathbf{Y}$$

для относительно небольшого кол-ва признаков и объема выборки можно использовать аналитическое решение:

$$\boldsymbol{\theta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

	X_0	X_1	X_2	\mathbf{Y}
1	1	x_{11}	x_{12}	y_1
2	1	x_{21}	x_{22}	y_2
...				
n	1	x_{n1}	x_{n2}	y_n

\mathbf{X}

$$\mathbf{X}_{[n \times (m+1)]}, \quad \mathbf{Y}_{[n \times 1]}, \quad \boldsymbol{\theta}_{[m+1, 1]},$$

Обучение с учителем: Классическая регрессия

Постановка задачи классической регрессии

Полиномиальная регрессия. Сведение к линейной

$$y(x_1, x_2, \dots, x_k) = \theta_0 + \sum_{k=1}^p \sum_{i=1}^k \theta_{(p-1)k+i} x_i^p + \sum_{\substack{i,j=1 \\ i \neq j}}^k \theta_{pk+i} x_i x_j$$

Например, $p = 2, k = 2$:

$$y(x_1, x_2) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \theta_5 x_1 x_2,$$

	X_0	X_1	X_2	X_3	X_4	X_5	Y
1	1	x_{11}	x_{12}	x_{11}^2	x_{12}^2	$x_{11}x_{12}$	y_1
2	1	x_{21}	x_{22}	x_{21}^2	x_{22}^2	$x_{21}x_{22}$	y_2
...							...
n	1	x_{n1}	x_{n2}	x_{n1}^2	x_{n2}^2	$x_{n1}x_{n2}$	y_n

X

пусть $x_3 = x_1^2, x_4 = x_2^2, x_5 = x_1 x_2$.

$$y(x_1, \dots, x_5) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \theta_4 x_4 + \theta_5 x_5,$$

$$J(\theta) = \frac{1}{n} \sum_{i=1}^n (\theta_0 + \theta_1 x_{i1} + \dots + \theta_5 x_{i5} - y_i)^2 \rightarrow \min$$

$$\frac{\partial J}{\partial \theta_j} = 0, j = 0..5$$


$$\theta = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \\ \theta_4 \\ \theta_5 \end{pmatrix}$$

Обучение с учителем: Классическая регрессия

Метод градиентного спуска

$f = f(\boldsymbol{\theta})$ - скалярная функция, $\boldsymbol{\theta} = (\theta_j)$, $j = 0, \dots, m$

$f_{min} = f(\boldsymbol{\theta}^*)$ - минимум (экстремум) функции, $\boldsymbol{\theta}^*$ - точка минимума (экстремума)



Инициализация:

- α - шаг градиентного спуска (скорость обучения);
- $\boldsymbol{\theta}^0 = (\theta_j^0)$ - начальное приближение точки минимума;
- $J^0 = J(\boldsymbol{\theta}^0)$ - начальное значение экстремума;
- $\nabla J^0 = \left\| \frac{\partial J(X)}{\partial \theta_j} \right\|^0$ - значение градиента в начальной точке.

Градиентный спуск:

- Шаг градиентного спуска:


$$\theta_j^{l+1} = \theta_j^l - \alpha \frac{\partial J}{\partial \theta_j} |_l \text{ или } \boldsymbol{\theta}^{l+1} = \boldsymbol{\theta}^l - \alpha \nabla J |_l$$

- Компоненты градиента и значение функции на текущем шаге l :

$$\nabla J^{l+1} = \left\| \frac{\partial J(X)}{\partial \theta_j} \right\|^{l+1}, \quad J^{l+1} = J(\boldsymbol{\theta}^{l+1})$$

Условие останова:

$$opt = [\boldsymbol{\theta}^{l+1}, J^{l+1}] \text{ if } \|\nabla J^{l+1}\| < \varepsilon$$



Обучение с учителем: Классическая регрессия

Численный расчет весовых коэффициентов методом градиентного спуска

Компоненты градиента:


$$\frac{\partial J(\boldsymbol{\theta})}{\partial \theta_j} = \frac{2}{n} \sum_{i=1}^n (h(x_{ij}) - y_i) x_{ij} \quad \Bigg| \quad \nabla J = \frac{2}{n} \mathbf{X}^T (\mathbf{H} - \mathbf{Y}),$$

Расчет коэффициентов на каждом шаге $l+1$:

$$\theta_j^{l+1} = \theta_j^l - \alpha \frac{\partial J}{\partial \theta_j} \Big|_l \quad \Bigg| \quad \boldsymbol{\theta}^{l+1} = \boldsymbol{\theta}^l - \alpha \nabla J \Big|_l$$

Значение функции ошибки на каждом шаге $l+1$:

$$J \Big|_{l+1} = \frac{1}{n} \sum_{i=1}^n (h(\boldsymbol{\theta}, \mathbf{X}_i) - y_i)^2 \quad \Bigg| \quad J \Big|_{l+1} = \frac{1}{n} (\mathbf{X} \boldsymbol{\theta}^{l+1} - \mathbf{Y})^T (\mathbf{X} \boldsymbol{\theta}^{l+1} - \mathbf{Y})$$



Gradient descent intuition

$\nabla J \Big|_l = \left(\frac{\partial J}{\partial \theta_j} \right) \Big|_l$ — компоненты градиента рассчитываются на каждом шаге l ;

$\boldsymbol{\theta}^0 = (\theta_j^0)$ — начальное значение коэффициентов;

α — шаг градиентного спуска (скорость обучения).


Обучение с учителем: Классическая регрессия

Метод стохастического градиентного спуска (SGD)

Проблема: большой обучающий набор необходим для более качественного обобщения, но обучение на нем обходится дорого с точки зрения вычислений

$J = J(\theta)$ - скалярная функция, $\theta = (\theta_j), i = 0, \dots, m$

$J_{min} = J(\theta^*)$ - минимум (экстремум) функции, θ^* - точка минимума (экстремума)



Основные шаги алгоритма SGD аналогичны классическому градиентному спуску:

- Инициализация начального решения θ^0 ;
- Шаг градиентного спуска $\theta_j^{l+1} = \theta_j^l - \alpha \frac{\partial J}{\partial \theta_j} |_l$;
- Проверка условия остановки.

Компоненты градиента на каждом шаге l по случайно выбранной точке* $(X_s, y_s) = (1 \ x_{s1} \ x_{s2} \ x_{sm}, y_s)$:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{2}{n} (h(X_s) - y_s) x_{sj}$$

	x_0	x_1	...	x_m	y
1	1	x_{11}		x_{12}	y_1
...					
s	1	x_{s1}		x_{sm}	y_s
...					
n	1	x_{n1}		x_{n2}	y_n

$\xrightarrow{X_s}$

* Случайный выбор выполняется на каждом шаге


Обучение с учителем: Классическая регрессия

Метод стохастического градиентного спуска (SGD)

Проблема: большой обучающий набор необходим для более качественного обобщения, но обучение на нем обходится дорого с точки зрения вычислений

$J = J(\theta)$ - скалярная функция, $\theta = (\theta_j), i = 0, \dots, m$

$J_{min} = J(\theta^*)$ - минимум (экстремум) функции, θ^* - точка минимума (экстремума)



Основные шаги алгоритма Mini-batch аналогичны классическому градиентному спуску:

- Инициализация начального решения θ^0 ;
- Шаг градиентного спуска $\theta_j^{l+1} = \theta_j^l - \alpha \frac{\partial J}{\partial \theta_j} |_l$;
- Проверка условия остановки.

Компоненты градиента на каждом шаге l по случайной выборке $\{X_s, Y_s\}$ (мини-батч) объема n' из $\{X, Y\}$:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{2}{n} \sum_{s=1}^{n'} (h(X_s) - Y_s) X_{sj}$$

	X_0	X_1	...	X_m	Y
1	1	x_{11}		x_{12}	y_1
...					
n'	1	x_{n1}		x_{n2}	$y_{n'}$
X_s					Y_s

* Случайный выбор выполняется на каждом шаге